

Desafío - Fundamentos de análisis exploratorio y estadística descriptiva

En este desafío validaremos nuestros conocimientos de Correlación y modelamiento. Para lograrlo, necesitarás aplicar lo visto en las sesiones de clases.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 2 horas cronológicas.

Descripción

Una empresa desarrolladora de videojuegos te ha contratado como analista de datos. Tu misión es analizar un dataset histórico de ventas de videojuegos (videojuegos.csv) para entender qué factores se relacionan con el éxito en ventas. Específicamente, el equipo de desarrollo quiere saber si existe una relación entre las puntuaciones de la crítica y las ventas, y si es posible predecir las ventas basándose en estas y otras variables.

Columnas principales a utilizar:

- Critica_Puntaje: Puntuación numérica asignada por críticos (de 0 a 100).
- Ventas_NA: Ventas en Norteamérica (en millones).
- Ventas_EU: Ventas en Europa (en millones).
- Ventas_JP: Ventas en Japón (en millones).
- Plataforma: Consola en la que se lanzó el juego.
- Genero: Género del videojuego.

Requerimientos

1. Preparación de Datos (2 Puntos):

- Carga el archivo `videojuegos.csv` en un DataFrame de Pandas.
- Crea una nueva columna llamada `Ventas_Globales` que sea la suma de `Ventas_NA`, `Ventas_EU` y `Ventas_JP`.
- Existen valores nulos en `Critica_Puntaje`. Rellena estos valores utilizando la **mediana** de la columna. Muestra el antes y el después de la cantidad de nulos.

2. Visualización de la Correlación (2 Puntos):

- Genera un **gráfico de dispersión (scatterplot)** para visualizar la relación entre `Critica_Puntaje` (eje X) y `Ventas_Globales` (eje Y).
- Calcula e informa el coeficiente de **correlación de Pearson (r-Pearson)** entre `Critica_Puntaje` y `Ventas_Globales`.
- Interpreta el gráfico y el coeficiente. ¿Qué puedes decir sobre la dirección y la fuerza de la relación?

3. Causalidad vs. Correlación (2 Puntos):

- Basándote en el resultado anterior, ¿podrías afirmar que una puntuación alta de la crítica *causa* un aumento en las ventas globales? Justifica tu respuesta explicando la diferencia entre **causalidad y correlación**.

4. Implementación del Modelo (1 Punto):

- Define tu variable dependiente (*y*) como `Ventas_Globales` y tu variable independiente (*x*) como `Critica_Puntaje`.
- Utilizando la librería `statsmodels`, implementa un **modelo de regresión lineal simple**.
- Muestra el resumen (`summary()`) del modelo.

5. Interpretación del Modelo (1 Punto):

- Interpreta los **coeficientes de regresión** (la constante/intercepto y el coeficiente de `Critica_Puntaje`). ¿Qué significan en el contexto de este problema?
- Interpreta el valor de **R-cuadrado (R2)**. ¿Qué tan bien explica el modelo la variabilidad de las ventas globales?

6. Implementación del modelo de regresión simple (1 Punto):

- Define tu variable dependiente (*y*) como `Ventas_Globales` y tu variable independiente (*x*) como `Critica_Puntaje`.
- Utilizando la librería `statsmodels`, implementa un **modelo de regresión lineal simple**.

- Muestra el resumen (`summary()`) del modelo.

7. Interpretación del Modelo de regresión simple (1 Punto):

- Interpreta los **coeficientes de regresión** (la constante/intercepto y el coeficiente de `Critica_Puntaje`). ¿Qué significan en el contexto de este problema?
- Interpreta el valor de **R-cuadrado (R2)**. ¿Qué tan bien explica el modelo la variabilidad de las ventas globales?



¡Mucho éxito!