

Desafío - Fundamentos del método científico y probabilidad

En este desafío validaremos nuestros conocimientos de Fundamentos del método científico y probabilidad. Para lograrlo, necesitarás aplicar lo aprendido hasta el momento.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 1 hora cronológica.

Descripción

Eres analista de datos para una plataforma de streaming de música. Se te ha proporcionado un conjunto de datos que simula la actividad de los usuarios durante un mes. Tu objetivo es utilizar tus conocimientos de probabilidad y técnicas de muestreo para analizar el comportamiento de los usuarios, específicamente en relación con la suscripción al servicio "Premium".

Resultado de Aprendizaje a Evaluar:

Aplicar los principales conceptos de probabilidad asociados a un evento aleatorio según el análisis estadístico.

Instrucciones

Utiliza el siguiente código para generar el conjunto de datos poblacional. Este DataFrame representa a toda tu población de usuarios.

```
Python
import pandas as pd
import numpy as np

np.random.seed(42)

# Crear la población de 1000 usuarios
data = {
    'user_id': range(1, 1001),
    'pais': np.random.choice(['México', 'Colombia', 'Argentina', 'Chile'],
                             1000, p=[0.4, 0.3, 0.2, 0.1]),
    'tiene_premium': np.random.choice([True, False], 1000, p=[0.35, 0.65])
}
poblacion_df = pd.DataFrame(data)

# Asegurar que algunos usuarios de Chile tengan premium para el cálculo de
intersección
idx_chile = poblacion_df[poblacion_df['pais'] == 'Chile'].index
poblacion_df.loc[np.random.choice(idx_chile, 10, replace=False),
                 'tiene_premium'] = True
```

Requerimientos

1. Probabilidad Teórica (Sobre la Población Total): (3 Puntos)

- Define los siguientes eventos:
 - **Evento A:** Que un usuario sea de 'Chile'.
 - **Evento B:** Que un usuario tenga una suscripción 'Premium'.
- Calcula las siguientes probabilidades basándote en el DataFrame `poblacion_df`:
 - La probabilidad del Evento A: $P(A)$.
 - La probabilidad del Evento B: $P(B)$.
 - La probabilidad de la **intersección** de ambos eventos: que un usuario sea de 'Chile' **y** tenga 'Premium' $P(A \cap B)$.
 - La probabilidad de la **unión** de ambos eventos: que un usuario sea de 'Chile' **o** tenga 'Premium' $P(A \cup B)$.

2. Muestreo Aleatorio Simple: (2 Puntos)

- Obtén una **muestra aleatoria simple** de 150 usuarios de la población total.
- Sobre esta nueva muestra, calcula la probabilidad empírica de tener 'Premium' $P(B)$.

3. Muestreo Estratificado: (3 Puntos)

- Obtén una **muestra estratificada** de 150 usuarios, asegurando que la proporción de usuarios de cada `pais` en la muestra sea la misma que en la población.
- Sobre esta muestra estratificada, calcula nuevamente la probabilidad empírica de tener 'Premium' $P(B)$.

4. Análisis corto de resultados: (2 Puntos)

- En un comentario (`#`) dentro de tu script, compara las tres probabilidades del evento B (Poblacional, Muestreo Simple, Muestreo Estratificado) que calculaste. Explica brevemente por qué los valores de las muestras pueden diferir del valor poblacional.



¡Mucho éxito!