

Desafío - Fundamentos del método científico y probabilidad

En este desafío validaremos nuestros conocimientos de Distribuciones de probabilidad muestreo. Para lograrlo, necesitarás aplicar lo aprendido hasta el momento.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 2 horas cronológicas.

Descripción

Eres un analista de datos en una empresa de logística nacional. La empresa ha registrado los tiempos de miles de entregas y quiere entender la variabilidad en los tiempos promedio de entrega para poder ofrecer mejores estimaciones a los clientes.

Tu tarea es demostrar el Teorema del Límite Central (TLC) y utilizar la distribución muestral de la media para calcular la probabilidad de observar ciertos resultados en una muestra de entregas.

Resultado de Aprendizaje a Evaluar:

- Realizar cálculos de probabilidad utilizando la distribución muestral para resolver un problema.

Instrucciones

Utiliza el siguiente código para generar la población de datos. Este DataFrame simula los tiempos de entrega (en minutos) de todas las entregas realizadas por la empresa.

```
Python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# Generar datos consistentes para todos
np.random.seed(10)
```

```
# Generamos una población con una distribución Gamma (no normal)
# Parámetros de la distribución Gamma
shape, scale = 2.5, 30
poblacion_tiempos = np.random.gamma(shape, scale, 5000)

# Calculamos la media y desviación estándar REAL de la población
media_poblacional = np.mean(poblacion_tiempos)
std_poblacional = np.std(poblacion_tiempos)

print(f"La media poblacional ( $\mu$ ) es: {media_poblacional:.2f} minutos")
print(f"La desviación estándar poblacional ( $\sigma$ ) es: {std_poblacional:.2f} minutos")

# Visualizamos la distribución de la población (que no es normal)
sns.histplot(poblacion_tiempos, kde=True)
plt.title("Distribución de Tiempos de Entrega (Población Total)")
plt.xlabel("Tiempo de Entrega (minutos)")
plt.ylabel("Frecuencia")
plt.show()
```

Requerimientos

1. Simulación de la Distribución Muestral:

- Toma 1000 muestras aleatorias de la población. Cada muestra debe tener un tamaño de $n=40$.
- Para cada una de las 1000 muestras, calcula su media.
- Guarda todas las medias de las muestras en una lista o arreglo de NumPy llamado `medias_muestrales`.

2. Análisis del Teorema del Límite Central (TLC):

- Calcula la media y la desviación estándar de tu lista `medias_muestrales`.
- **Compara tus resultados:**
 - ¿La media de las medias muestrales es similar a la `media_poblacional`?
 - Calcula el error estándar teórico usando la fórmula del TLC:
 $SE = \frac{\sigma}{\sqrt{n}}$. ¿Este valor es similar a la desviación estándar que obtuviste de tus `medias_muestrales`?
- Genera un histograma de las `medias_muestrales`. ¿Qué forma tiene esta distribución?
- *Escribe tus respuestas a las preguntas de comparación como comentarios en el código.*

3. Cálculo de Probabilidades:

- Asumiendo que la distribución de las medias muestrales es normal (gracias al TLC), **calcula la probabilidad de que una muestra aleatoria de 40 entregas tenga una media de 72 minutos o menos.**
- Deberás estandarizar el valor (calcular el Z-score) y utilizar la distribución normal estándar para encontrar esta probabilidad.



¡Mucho éxito!